

労働経済学

Lecture 8 実証研究における因果的効果の識別 差の差 (Differences-in-Differences)

張 俊超

6th June 2017

固定効果モデルの問題点

- ① Demean 法または一階差分で推定するとき、測定誤差が大きくなる。測定誤差の部分が「説明変数」の値に占める割合が大きくなるから。
- ② 通常の固定効果モデルであれば、個人の複数年のデータの間、変数の Variation で識別。年間の Variation がないと、識別できない。または、Variation が少ないとき、統計的に有意な結果が出にくい。(因果効果はあるかもしれないが、識別戦略が失敗し、因果効果を見出せなくなる。)
 - ▶ 大人の教育年数は一定であり、時間に通じて変化しないこと。
 - ▶ ボランティア活動に参加する人は常に参加し、参加しない人は常に参加しない。ボランティア活動参入の年間の Variation が非常に小さい。(ダミー変数の場合)
- ③ 年間の Variation があったとしても、その Variation が外生的ではない。(例：個人は何らかの理由で、喫煙本数を減す)

固定効果の推定には

- ▶ 一階差分の推定量は系列相関が出るため、Demean 法がより望ましい。しかし、不均一分散に頑健な標準誤差を扱う時、LSDV(ダミー変数での固定効果推定) がより望ましい。
- ▶ より良い識別戦略ができる場合、固定効果モデルを使用しないこと。(双子の固定効果推定量は例外だが、双子のデータの取得は困難。) 固定効果モデルは時間に通じて変化しない、観測できない要因しか取り除けない。

Before and After

- ▶ 治療の処置において、前後の結果変数の差を比較することで、処置効果を測定できる。

	処置群
Before	$E(Y_0)$
After	$E(Y_1)$
差	$E(Y_1) - E(Y_0)$

- ▶ しかし、処置の時、何かが同時に生じてしまう可能性が高い。その場合、before and after で推定したものはバイアスがある。対照群と比較することで、同時に変化した要素を考慮できる。

Differences-in-Differences(差の差)

処置前後に比較した上で、処置群と対照群を比較する手法は Differences-in-Differences(差の差) と呼ばれる。

	処置群	対照群
Before	$E(Y_0 D=1)$	$E(Y_0 D=0)$
After	$E(Y_1 D=1)$	$E(Y_1 D=0)$
差	$E(Y_1 D=1) - E(Y_0 D=1)$	$E(Y_1 D=0) - E(Y_0 D=0)$

$$DID = [E(Y_1|D=1) - E(Y_0|D=1)] - [E(Y_1|D=0) - E(Y_0|D=0)]$$

DID は政策介入の分析によく使われる。

図で見る DID




Figure 5.2.1 Causal effects in the DD model.

出所：Mostly Harmless Econometrics p231

回帰分析での DID (二期間)

処置前後、そして処置群と対照群との間の平均の差を計算し、引き算より DID 推定量が得られるが、他の要因をコントロールするのは不便。回帰分析で DID 推定する場合、コントロール変数を簡単に入れる。単純化のために、以下はコントロール変数のないモデルを考える。

$$y_{it} = \beta_0 + \beta_1 Treated_i + \beta_2 After_t + \beta_3 (Treated * After)_{it} + \varepsilon_{it}$$

	処置群	対照群	差
Before	$\beta_0 + \beta_1$	β_0	-
After	$\beta_0 + \beta_1 + \beta_2 + \beta_3$	$\beta_0 + \beta_2$	-
差	$\beta_2 + \beta_3$	β_2	β_3


β_3 は DID 推定量。

DID に必要な仮定：Common Trends

- ▶ DID が有効な推定量になるために、一つの重要な仮定を満たさないといけない。それは、common trends assumption または parrell trends assumption と呼ばれる。
- ▶ Common trends とは、処置群と対照群との間に、処置がなければ、時間を通じての変化が同じ傾向を持つこと。（両方増加、両方減少、両方変わらない）
- ▶ Common trends は結果変数の平均がグループ間では同じを意味しない。平均が異なってもいい。
- ▶ Common trends の検証は難しいが、一般的に処置前のデータでグループ間の傾向が同じかどうかを確認できる。
- ▶ 処置前、処置群と対照群が同じトレンドを持ったとしても、処置と同じ時点での政策変化に注意しないといけない。

DID に必要な仮定：Common Trends

処置前のトレンドをチェックするために、少なくとも 3 期間以上のデータが必要。推定には 2 期間だけで十分。



Card & Krueger (1994): 最低賃金の効果

- ▶ Card & Krueger (1994) はアメリカの最低賃金改革が雇用 (人数) に与える効果を分析した。この政策は New Jersey(NJ) 州で実施したが、隣の Pennsylvania(PA) 州では実施していなかった。まるで実験のように、処置群と対照群が分けられた。このような、偶発的に処置群と対照群への割当が自然実験と呼ばれる。
- ▶ 単純な before and after で雇用人数を比較すると、全国的なデフレの効果を含まれる可能性がある。時間上の変化だけでなく、対照群との比較が必要。
- ▶ NJ は処置群、PA は対照群となる。この政策は 1992 年の 11 月に実施した。

$$E_{it} = \beta_0 + \beta_1 N_{7i} + \beta_2 Nov92_t + \beta_3 (N_{7i} * Nov92_t) + \varepsilon_{it}$$

推定された $\hat{\beta}_3 = 2.75$ 、最低賃金を増やすことが雇用に正の効果があるが、統計的に有意ではない。

Stata での DID 推定

	ID	year	location	smoking	after	treated	dpolicy
1	1	2000	2	2.560392	0	1	0
2	1	2010	2	9.205175	1	1	1
3	2	2000	2	9.200375	0	1	0
4	2	2010	2	.0717783	1	1	1
5	3	2000	2	6.033484	0	1	0
6	3	2010	2	4.224289	1	1	1
7	4	2000	1	4.290424	0	0	0
8	4	2010	1	8.899221	1	0	0
9	5	2000	1	5.803893	0	0	0
10	5	2010	1	8.629035	1	0	0
11	6	2000	2	8.624993	0	1	0
12	6	2010	2	.0158829	1	1	1
13	7	2000	1	8.792822	0	0	0
14	7	2010	1	9.333986	1	0	0

Stata での DID 推定

```

. /* DID推定 */
. reg smoking treated after dpolicy

```

Source	SS	df	MS	Number of obs	=	1,000
				F(3, 996)	=	1.74
Model	41.0512339	3	13.6837446	Prob > F	=	0.1575
Residual	7842.08762	996	7.87358195	R-squared	=	0.0052
				Adj R-squared	=	0.0022
Total	7883.13885	999	7.89102988	Root MSE	=	2.806

smoking	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	
treated	-.28718	.2509754	-1.14	0.253	-.7796813	.2053212
after	-.0773796	.2509754	-0.31	0.758	-.5698809	.4151216
dpolicy	-.1570372	.3549328	-0.44	0.658	-.8535392	.5394647
_cons	5.115384	.1774664	28.82	0.000	4.767134	5.463635

三期間以上の DID

三期間以上の DID 推定では、説明変数がその時点の政策介入ダミー、固定効果モデルとして、以下のような式で推定できる。

$$y_{it} = \beta_0 + \beta_1 D_{policy_{it}} + \sum \gamma_i D_{location_{it}} + \sum \tau_t D_{year_{it}} + \varepsilon_{it}$$

この式は、LSDV での固定効果推定式と同様であり、DID は実質的に、固定効果モデルである。注意してほしいのは、標準の固定効果モデルでは、説明変数の変化はランダムではない。DID は自然実験による外生的な変動を用いて、固定効果を行うこと。一般的に、DID での説明変数は個人レベルではない。

連続変数の場合


現実には、長期間のデータで 01 のダミー変数は政策の変動を細かく捉えないかもしれない。01 ダミー変数の代わりに、処置変数が連続変数でも DID が使用可能。

$$y_{it} = \beta_0 + \beta_1 Policy_{it} + \sum \gamma_i Dlocation_{it} + \sum \tau_t Dyear_{it} + \varepsilon_{it}$$

連続変数の $Policy_{it}$ が政策などの強さだと考えてよい。

Kondo & Shigeoka(2012)

Kondo & Shigeoka(2012) は国民健康保険のカバー率の拡大が需要側（通院の人数など）や供給側（病院の数など）に与える効果を分析した。国民健康保険のカバー率は急に 0 から 1 になるわけがない。徐々に増えていた。



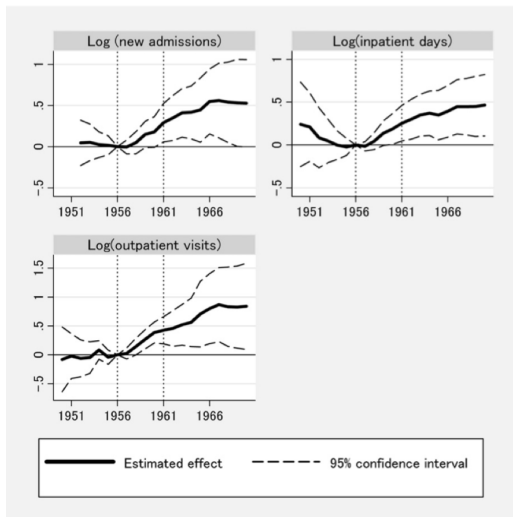
Kondo & Shigeoka(2012)

$$Y_{pt} = \alpha_p * 1(pref_p) + \delta_{rt} * 1(year_t) * 1(pref_p \in region_r) \\ + \kappa_t * Y_{p1956} * 1(year_t) + \sum_{t \neq 1956} \lambda_t (impact_p) * 1(year_t) + X_{pt} \beta + \varepsilon_{pt} \quad (1)$$

- ▶ データは都道府県パネルであり、 p は都道府県、 t は年を指す。
- ▶ Specification は単純な DID とちょっと異なるが、識別戦略の仕組みは変わらない。
- ▶ λ_t は推定したい DID 推定量、 $impact_p$ は都道府県別の健康保険にカバーされない人の割合。 α_p は都道府県固定効果、 δ_{rt} は地域別の時間固定効果。改革前の水準をコントロールするために、結果変数のラグ Y_{p1956} が含まれる。

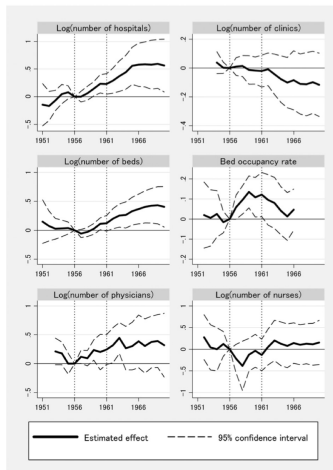
Kondo & Shigeoka(2012)

国民健康保険の介入によって、医療施設の利用が増えていた。



Kondo & Shigeoka(2012)

国民健康保険の介入によって、供給側（病院の数、ベッドの数）の一部が増えていた。医者、看護師の増加は統計的に有意でない。



DID における結果変数のラグ

Kondo & Shigeoka(2012) は標準の DID より、追加的に結果変数のラグ値 (lag) をコントロールした。DID モデルでは、処置前の状態を一定を保つために、結果変数のラグを入れることで考慮する。(推定される DID 推定量は政策変化によるものではなく、処置群と対照群の処置前の差による恐れがある。)DID で、ある政策が個人に与える効果を分析するとき、

$$Y_{ijt} = \beta_0 + \beta_1 Policy_{jt} + \beta_2 Y_{ijt-1} + \beta_3 Y_{ijt-2} \dots + \gamma_j + v_t + \varepsilon_{ijt}$$

ラグ変数の数はパネルの長さに制限される。

DID における処置変数のラグとリード

パネルが長いと、処置効果の時間を通じての変化を分析できる。リード変数の係数は処置後（1 期、2 期、3 期... 後）の処置効果を表す。ラグ変数を入れることで、処置前のトレンドが分析しやすい。

$$Y_{ijt} = \beta_0 + \beta_1 Policy_{jt} + \beta_2 Policy_{ijt+1} + \beta_3 Policy_{ijt+2} \dots + \gamma_j + v_t + \varepsilon_{ijt}$$

$$Y_{ijt} = \beta_0 + \beta_1 Policy_{jt} + \beta_2 Policy_{ijt-1} + \beta_3 Policy_{ijt-2} \dots + \gamma_j + v_t + \varepsilon_{ijt}$$